

EchoFusion

出处会议: NeurIPS 2023

是否开源: <https://github.com/tusen-ai/EchoFusion>

关键词: 原始雷达数据融合、极坐标 BEV、极坐标对齐注意力 (PAA)、3D 目标检测

1. 概述

传统的雷达-摄像头融合方法通常依赖于经过 CFAR 检测后生成的稀疏雷达点云。这种流程会丢失大量包含弱回波信号的原始信息，且点云的方位角分辨率较低。

EchoFusion 提出了“跳过信号处理”的范式，直接在 **极坐标 BEV 空间** 下融合原始雷达特征（如 Range-Time 图）与图像语义特征。其核心是通过几何约束实现两种模态在特征层面的精确对齐。

2. 技术实现

EchoFusion 采用基于 Transformer 的架构，其核心组件包括极坐标 BEV 查询初始化、极坐标对齐注意力（PAA）以及极坐标解码头。

2.1 极坐标对齐注意力 (Polar-Aligned Attention, PAA)

PAA 模块利用 3D 空间与传感器数据维度之间的几何对应关系，分两步进行特征聚合：

1. 列向图像融合 (Column-wise Image Fusion)

公式推导：

$$x_I \approx u_0 + f_x \frac{-r \sin \phi + d_1}{r \cos \phi + d_3} \approx u_0 - f_x \tan \phi_{bev}$$

当距离 r 远大于相机偏移量 d 时， r 被约去， x_I 仅取决于 ϕ 。

这意味着对于给定的方位角 ϕ_{bev} ，无论距离 r_{bev} 是多少，其投影在图像上的横坐标 x_I 几乎是恒定的。因此，在极坐标 BEV 空间中，沿着同一条射线（固定 ϕ ）的所有点都会投影到图像的同一列。

由于上述距离抵消特性，同一个 ϕ 扇区内的所有 Pillar 在图像上横向重叠。因此，模型将同一方位角 ϕ 下的所有 BEV Queries 聚合在一起，与图像对应列 x_I 的特征进行 Cross-Attention。这种设计使得网络能够学习从图像的垂直空间信息（高度）中提取特征，以填充 BEV 空间中缺失的深度/高度线索。

2. 行向雷达融合 (Range-wise Radar Fusion)

BEV 查询 (Q_{bev}): 经过列向图像融合 (Column-wise Image Fusion) 更新后的特征，维度表示为 $Q \in \mathbb{R}^{R \times A \times d}$ ，其中 R 是径向距离切分数量， A 是方位角切分数量， d 是特征维度。

雷达特征图 (F_R): 通常采用距离-时间 (Range-Time, RT) 图作为输入，维度表示为 $F_R \in \mathbb{R}^{R_I \times T_I \times d}$ 。其中 R_I 是距离 Bin 的数量， T_I 是 Chirps (或时间步) 的数量。

极坐标 BEV 的径向距离 r 与雷达距离-时间 (RT) 图的距离轴天然对齐。

对于 BEV 空间中任意一个位于距离索引 r 、方位角索引 ϕ 的查询向量 $q(r, \phi)$ ，其在雷达 RT 图中对应的物理信息仅存在于第 r 行（即相同的距离 Bin）。

在同一距离 r 下，所有的方位角查询 $\{q(r, \phi_1), q(r, \phi_2), \dots, q(r, \phi_A)\}$ 都对应 RT 图中的同一行特征 $\{F_R(r, t) \mid t = 1, \dots, T_I\}$ 。

每一个距离索引为 r 的 BEV Query 只与 RT 特征图中第 r 行的特征（跨越所有时间步/Chirps）进行交互。

$$\tilde{q}(r, \phi) = \text{Attention}(q(r, \phi), F_R(r, \cdot), F_R(r, \cdot))$$

效果：保留了无损的距离和速度（多普勒）信息，隐式提取目标的方位角线索。

2.2 极坐标解码器与回归分支

检测头在极坐标系下直接预测目标属性，避免了笛卡尔坐标转换带来的插值失真。

- 极坐标交叉注意力：**对象查询（Object Queries）在极坐标网格中生成参考点 $(\hat{\rho}, \hat{\phi})$ ，并直接采样对应的 BEV 特征。
- 回归参数化：**
 - 位置：**预测极坐标偏移 $(\Delta\rho, \Delta\phi)$ 和高度 z 。
 - 尺寸：**预测 $(\log l, \log w, \log h)$ 。
 - 朝向：**预测相对于极坐标轴的偏航角 $(\sin \theta, \cos \theta)$ 。

3. 实验结果

论文在 RADial 数据集上进行了核心评估，对比了不同模态组合及其在 3D 检测任务中的表现。

3.1 RADial 数据集主要性能对比

方法 (Methods)	模态 (Modality)	AP (%)	AR (%)	F1 (%)	RE (m)	AE (°)
FFTRadNet	RD	96.84	82.18	88.91	0.11	0.17
ADCNet	ADC	95.00	89.00	91.90	0.13	0.11
EchoFusion (Ours)	RT + Image	96.95	93.43	95.16	0.12	0.18

3.2 消融实验：雷达数据格式与模态影响

实验编号	模态组合	雷达格式	mAP (%)	NDS (%)
1	仅图像	-	19.3	31.9
2	图像 + PCD	稀疏点云	33.1	47.9
3	图像 + RA Map	距离-方位图	38.6	54.7
4	图像 + RT Map	距离-时间图	42.4	59.3

3.3 坐标系选择对比

坐标系 (Coordinate System)	mAP (%)	NDS (%)
直角坐标系 (Cartesian)	41.5	58.6
极坐标系 (Polar)	42.4	59.3

4. 核心结论

- 原始数据的优越性**：RT 图提供的连续能量分布远优于经过硬阈值过滤后的雷达点云 (PCD)。
- 几何对齐机制**：通过 PAA 模块在极坐标下解耦方位角（对应图像列）和距离（对应雷达行），实现了高效的多模态特征聚合。
- 极坐标回归**：直接在极坐标空间进行边界框回归，能够更好地适应雷达传感器的测量特性。

附录

FMCW 雷达信号处理的本质是对一个三维数据立方体 (Data Cube) 进行多维离散傅里叶变换 (DFT)。以下通过数学表达描述从原始采样到各类特征图的演进关系。

设定基础参数：

- N_s : 每个 Chirp 的采样点数（快时间维度）。
- N_c : 每帧的 Chirp 数量（慢时间维度）。
- N_a : 接收天线通道数（空间维度）。
- $S \in \mathbb{C}^{N_s \times N_c \times N_a}$: 原始 ADC 采样数据立方体。

1. ADC 原始数据 → RT 图 (Range-Time Map)

算子：Range-FFT

对快时间维度 n_s 进行一维 FFT。对于任意天线通道 a 和第 m 个 Chirp：

$$X_{RT}(k, m, a) = \sum_{n_s=0}^{N_s-1} S(n_s, m, a) \cdot w_s(n_s) \cdot e^{-j \frac{2\pi}{N_{FFT,r}} k n_s}$$

其中 k 为距离门索引， w_s 为窗函数。

- 物理关系**： k 对应距离 $R = \frac{k \cdot c \cdot f_s}{2K \cdot N_{FFT,r}}$ (K 为扫频斜率, f_s 为采样率)。
- RT 图定义**：通常指固定 a 后的二维矩阵 $\mathbf{M}_{RT} \in \mathbb{C}^{N_{FFT,r} \times N_c}$ 。它保留了慢时间维度的相位演进 $\Delta\phi = \frac{4\pi v T_c}{\lambda}$ 。

2. RT 图 → RD 图 (Range-Doppler Map)

算子: Doppler-FFT

在 RT 图的基础上, 沿着慢时间维度 m (Chirp 轴) 进行第二次 FFT:

$$X_{RD}(k, l, a) = \sum_{m=0}^{N_c-1} X_{RT}(k, m, a) \cdot w_c(m) \cdot e^{-j \frac{2\pi}{N_{FFT,d}} lm}$$

- 物理关系:** l 对应多普勒频率, 进而对应径向速度 $v = \frac{l \cdot \lambda}{2N_c T_c}$ 。
- RD 图定义:** $\mathbf{M}_{RD} \in \mathbb{C}^{N_{FFT,r} \times N_{FFT,d}}$ 。此过程将时域的相位旋转相干积分转换为频域的能量峰值。

3. RD 图 → RA 图 (Range-Azimuth Map)

算子: Angle-FFT / Beamforming

对接收天线维度 a 进行第三次 FFT (针对等间距线阵 ULA) :

$$X_{RAD}(k, l, p) = \sum_{a=0}^{N_a-1} X_{RD}(k, l, a) \cdot w_a(a) \cdot e^{-j \frac{2\pi}{N_{FFT,a}} pa}$$

- 物理关系:** p 对应空间频率, 反映入射角 $\theta = \arcsin(\frac{p \lambda}{N_{FFT,a} d})$ (d 为阵元间距)。
- RA 图定义:** 通常通过对 X_{RAD} 在多普勒维度 l 进行能量累加或取最大值 (Max-pooling) 得到:

$$\mathbf{M}_{RA}(k, p) = \sum_{l=0}^{N_{FFT,d}-1} |X_{RAD}(k, l, p)|^2$$

4. RA 图 → RP 图 (Range-Polar Map)

算子: 坐标映射与特征重组

RP 图通常指极坐标下的 BEV 表征。在深度学习框架中, 它建立了从距离索引 k 和角度索引 p 到极坐标网格的直接映射。

若定义极坐标网格为 (r_i, θ_j) , 其映射关系为:

- 距离对齐:** $r_i = k \cdot \Delta R$, 即 N_r 个距离划分 (Range Partition) 与 RT/RD 图的距离门完全一致。
- 角度分布:** 将 Angle-FFT 得到的非线性分布角 $\theta = \arcsin(\dots)$ 重采样或映射到均匀分布的 θ_j 。

数学关系概括:

$$S(n_s, m, a) \xrightarrow{\text{FFT}_{n_s}} RT(k, m, a) \xrightarrow{\text{FFT}_m} RD(k, l, a) \xrightarrow{\text{FFT}_a} RAD(k, l, p) \xrightarrow{\text{Collapse } l} RA(k, p) \approx RP(r, \theta)$$

5. 核心逻辑链总结

- ADC** 是时域/空间域的原始离散采样复数张量。
- RT** 是距离域-时间域特征, 保留了原始速度线索 (相位演进趋势)。
- RD** 是距离域-频率域特征, 解耦了距离和速度, 是传统检测 (CFAR) 的输入。
- RA** 是距离域-角度域特征, 是水平面内目标定位的直接依据。
- RP** 是将上述特征按照极坐标几何逻辑组织的特征图, 用于与视觉等其他模态在统一的极坐标/BEV 空间内对齐。