

SparseOcc: Fully Sparse 3D Occupancy Prediction

出处会议: ECCV 2024

是否开源: <https://github.com/MCG-NJU/SparseOcc>

关键词: 全稀疏架构、占据预测、掩码引导稀疏采样、RayIoU、时序建模

1. 概述

解决 3D 占据预测中稠密代价卷 (Dense Cost Volume) 带来的 $O(L^3)$ 计算冗余问题。

SparseOcc 利用场景的固有稀疏性, 跳过稠密特征构建, 直接在稀疏空间进行几何重建与语义预测。

Images $\rightarrow$ Sparse Voxel Decoder $\rightarrow$ Mask Transformer $\rightarrow$ RayIoU Evaluation

彻底摒弃稠密的张量表示, 整个网络的数据流从头到尾仅维护一个**稀疏的非空 3D 坐标点集 (Sparse Token List)**。所有特征提取、语义分割均直接在离散的三维坐标点上执行。

2. 核心技术实现细节 (How)

2.1 稀疏体素解码器 (Sparse Voxel Decoder)

技术目标: 在不构建全局张量的前提下, 找出 3D 空间中存在物体的几何表面。

算子逻辑: 基于从粗到细 (Coarse-to-fine) 的层次化生成与空间剪枝。

- 空间初始化 (Layer 1):** 在 3D 空间生成极低分辨率的均匀体素网格查询 $Q_1 \in \mathbb{R}^{N_1 \times C}$ 。
- 自适应特征混合 (Adaptive Mixing):** 取代传统的 3D 卷积。对于每个活跃体素查询 q_i 及其物理坐标 P_i :
 - 通过线性层预测 K 个 3D 局部空间偏移量 ΔP_{ik} 。
 - 利用相机内外参矩阵将偏移后的 3D 点投影至多视图 2D 图像平面:
$$x_{v,k} = \mathbf{K}_v[\mathbf{R}_v | \mathbf{t}_v](P_i + \Delta P_{ik})$$
 - 在 2D 特征图上执行双线性插值采样, 并通过 q_i 生成的动态权重张量执行矩阵乘法聚合, 完成特征写入。
- 二分类剪枝 (Pruning):** 通过 MLP 预测当前尺度下 N_{active} 个体素的占据得分 $s \in [0, 1]$ 。执行硬过滤, 仅在内存中保留得分 $s > \tau$ 的 Token。
- 空间上采样:** 将保留下来的物理体素在 3D 坐标系中 8 等分 (各轴分辨率 $\times 2$)。子体素继承父级特征, 作为下一层的初始查询 Q_{l+1} 。
- 递归执行:** 重复上述过程 $L = 3$ 次。最终输出的 Token 列表仅覆盖高分率下的物理表面, 计算复杂度从 $O(L^3)$ 降至 $O(N_{active})$ 。

2.2 掩码 Transformer (Mask Transformer)

技术目标：在解码器提供的几何表面点集上，预测语义类别和实例。

传统方法痛点：标准 Mask2Former 的 Object Query 需要与所有 3D 体素进行全局交叉注意力计算，时间复杂度为 $O(N_{query} \cdot M_{voxel})$ 。在 3D 高分辨率下，体素基数过大导致算子无法执行。

解决路径：掩码引导稀疏采样 (Mask-guided Sparse Sampling, MGSS)

- 生成初始掩码分布：**查询向量 Q_m 与活跃体素特征计算点积，通过 Softmax 得到该实例在 3D 空间的初步概率分布张量 M_i 。
- 坐标点采样：**抛弃全局加权求和，将 M_i 作为离散概率密度函数，在 3D 物理空间中**随机采样**固定数量的 N_p 个点（如 96 个点）。
- 投影与更新：**将这 N_p 个采样点的 3D 坐标投影回 2D 图像获取特征，并更新该实例的 Object Query。

本质差异：将 Cross-Attention 的稠密矩阵乘法，降维成基于先验掩码分布的稀疏索引采样，复杂度被严格绑定为 $O(N_{query} \cdot N_p)$ 。

2.3 射线评估指标 (RayIoU)

技术目标：解决传统 mIoU 对深度轴惩罚不一致的问题。

计算流程：

- 模拟物理传感器的扫描行为，从自车相机中心向 3D 预测空间和真值空间投射高密度射线 r 。
- 在每条射线路径上，执行射线求交算法，记录其**首次**命中非空体素的类别 c 和深度距离 d 。
- 真正例 (TP) 判定算子：**一条射线被判为正确需同时满足两项布尔逻辑：
 - 语义类别绝对相等： $c_{pred} == c_{gt}$ 。
 - 深度 L1 误差满足阈值： $|d_{pred} - d_{gt}| < \tau$ (τ 设为 1m, 2m, 4m)。

指标影响：彻底封堵了模型通过“将表面预测得很厚”来提高体积重叠概率的作弊路径。只要表面首次接触点的深度位置错误，无论物体内部体积多大，该射线均判定为假正例 (FP)。

3. 实验数据与因果关联

测试环境：Occ3D-nuScenes 数据集，Tesla A100 (fp32)。

方法架构	3D 表示范式	时序输入	RayIoU	FPS (推理速度)
BEVFormer	稠密 (Dense Cost Volume)	4帧	32.2	2.3
FB-Occ	稠密 (Dense Cost Volume)	16帧	33.7	5.2
SparseOcc	全稀疏 (Sparse Tokens)	7帧	34.0	17.3

底层逻辑支撑：

- FPS 突破的数学解释：**解码器在低分辨率阶段物理抹除了 $> 90\%$ 的背景空间节点，后续所有算子（自注意力、投影、MLP）的矩阵维度仅取决于 N_{active} 。去除了体积依赖后，FPS 实现量级跃升。
- 长时序建模的资源释放：**全稀疏架构极大地降低了单帧特征的显存占用。通过坐标系变换矩阵 $T_{curr \rightarrow prev}$ 将

当前 3D 坐标直接映射到历史多帧图像上提取特征，系统能以极低代价处理 15 帧输入（RayIoU 达 35.1），补全了单帧图像中被遮挡的截断面。